



Recurrent Neural Network



Model이란?

현실 세계의 시스템을 단순화하여 수학적인 표현으로 변환한 구조로 이를 통해 현실 세계를 해석하고 설명

- 뉴턴 운동 법칙
- 수요-공급 모델
- 대기 순환 모델



인공지능에서의 모델

데이터에 내재된 패턴을 학습한 함수

$$\hat{y} = f(x; \theta) \quad \hat{y} = f_{\theta}(x)$$



NLP에서의 모델

일반적으로 언어 모델을 의미하며,

그 중에서도 언어의 확률적 구조를 학습한 모델을 의미

$$P(w_0, w_1, w_2, \dots, w_t)$$

$$P(w_t | w_0, w_1, \dots, w_{t-1})$$



확률적 언어 모델

각 단어의 확률은 이전 단어 시퀀스가 나왔을 때 다음 단어의 확률로, 전체 문장은 각 단어 확률의 곱으로 표현

$$P(W) = \prod_{i=0}^N P(w_i | w_0, w_1, \dots, w_{i-1})$$



N-gram

단어 시퀀스가 길어질 경우 계산이 어렵고 확률이 매우 낮아지기 때문에 N개까지를 기준으로 계산

$$\begin{aligned} &P(w_i | w_0, w_1, \dots, w_{i-1}) \\ &\approx P(w_i | w_{i-3}, w_{i-2}, w_{i-1}) \end{aligned}$$



N-gram의 문제점

- N이 커질 수록 조합 가능한 시퀀스들의 등장 확률이 급격하게 낮아짐
- 다음 단어 추론에 필요한 정보가 먼 거리에 있을때 모델이 이를 알 수 없음
- 단어의 의미와 맥락을 반영하기 어려움



N-gram의 근본적 원인

차를 마시다 / 커피를 마시다 / 우유를 마시다

위 텍스트는 구조적으로 매우 유사하지만 N-gram 방식에서는 전부 완전히 별개의 다른 상태로 취급

discrete symbol 대신 연속적인 표현 필요,

단어의 조합 대신 연속된 벡터를 사용



단어를 벡터로 변환

차 → [0.82, 0.14, 0.33, 0.57, 0.21]

커피 → [0.85, 0.18, 0.36, 0.60, 0.24]

우유 → [0.78, 0.11, 0.30, 0.52, 0.19]



Distributional Hypothesis


분포 가설의 핵심 : “A word is characterized by the company it keeps”

비슷한 문맥에서 등장하는 단어들은 비슷한 의미를 가진다


“나는 ____ (을)를 먹었다”

“나는 ____에 산다”


Distributional Hypothesis



Male-Female



Verb Tense



Country-Capital



N-gram + Word Vector + MLP

Neural Probabilistic Language Model

아주 초기 시도 중 하나.

N-1 개의 단어를 입력 받아 MLP에 입력하여 다음 단어를
추론


이 과정에서 Embedding Vector도 학습됨.



Recurrent Neural Network

- 순차 데이터 처리
- Hidden State를 통한 정보 전달
- 가중치 반복 사용
- 가변 길이

RNN의 구조





수식으로 보는 RNN

$$h_t = \tanh(W_h \cdot h_{t-1} + W_x \cdot x_t)$$



RNN의 한계

- Gradient Vanishing
- Gradient Exploding
- 긴 맥락에서 정보 소실

Long Short-Term Memory

