



텍스트 전처리



Preprocessing in NLP

좁은 의미 : raw text -> clean corpus

넓은 의미 : 데이터를 모델 학습에 사용 가능하도록
준비하는 모든 과정

이 과정에서의 의미 : padding 및 truncation을 포함한
batch 단위로 가공까지



인공지능 파이프라인

1. 데이터 수집
2. 데이터 정제
3. 표현 변환
4. 모델 입력
5. 텐서 계산
6. 출력 후 디코딩



데이터 수집

데이터 수집 이외에도 raw 시그널을 적절한 디지털 표현으로 변환하는 것을 내포

- 웹/문서 데이터(txt, HTML, PDF 등)
- 비정형 데이터(이미지, 센서 등)

데이터 수집 예시

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T \sqrt{d_k})V$$



데이터 수집 예시

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

`\begin{equation}`

`\mathrm{Attention}(Q, K, V) = \mathrm{softmax}(\frac{QK^T}{\sqrt{d_k}})V`

`\end{equation}`



데이터 정제

목표에 맞춰 필요한 내용만 남기는 것

- 불필요한 요소 제거(중복 문장 등)
- 정규화(대소문자 통일 등)
- 토큰화(문장, 문자 단위 등)



데이터 정제

`\begin{equation}`

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

`\end{equation}`



데이터 정제

Attention, (Q, K, V), $=, \text{softmax}, \frac{QK^T}{\sqrt{d_k}}, V$



모델은 자연어를 어떻게 이해하는가?

모델 연산은 숫자와 벡터로 진행.

따라서 자연어도 숫자와 벡터로 변환되어야함

토큰 -> 인덱스

인덱스 -> 임베딩 벡터



단어사전

모든 토큰을 모아서 사전을 생성

각 토큰에 고유 ID index를 부여

사과 : 11

포도 : 204



단어를 분할하는 방법 - 형태소

안녕하세요

안녕 하 시 어 요

NNG XSV EP EF JX



Subword

- 단어를 더 작은 단위로 분해
- 자주 등장하는 패턴을 유지
- 처음 보는 단어도 표현 가능
- OOV 문제 완화

안녕하세요 -> 안녕, 하, 세, 요



Byte Pair Encoding

자주 등장하는 문자 쌍을 반복적으로 합쳐 토큰을 만든다

1. 모든 문장을 문자 단위로 분해
2. 가장 자주 등장하는 문자 쌍을 탐색
3. 해당 쌍을 하나의 토큰으로 병합
4. 1~3을 반복해 더 큰 단위 생성
5. 필요한 크기의 단어사전이 구축되면 종료



WordPiece

병합했을 때 전체 데이터의 확률을 가장 잘 증가시키는 쌍을 선택한다

$$\frac{P(ab)}{P(a) \cdot P(b)}$$



Unigram Language Model

토큰을 만드는 것이 아닌 좋은 토큰을 선택하고 나쁜 토큰을 제거하자

1. 조합 가능한 subword를 생성
2. 확률 모델 정의
3. 영향력 적은 토큰을 하나씩 제거
4. 3을 반복하여 최종 단어사전 생성



Vectorization



자연어를 벡터로 만드는 방법

- BoW(Bag of Words)
- TF-IDF
- Word2Vec
- Embedding



BoW

텍스트(문장)을 단어의 빈도로 표현하는 방법

벡터의 각 항의 자리는 각각 단어와 매칭되고 각 항의 값은
그 단어가 문장에서 발생한 빈도로 표기



TF-IDF

단어의 중요도를 반영한 가중치

- TF : 문장 내 등장 빈도
- IDF : 전체 문서에서의 희귀성



Word2Vec

단어의 의미는 주변 단어로부터 결정되며 비슷한 문맥에서 등장하는 단어는 비슷한 의미를 가졌다.

비슷한 단어는 비슷한 벡터 값을 부여


-> 비슷한 단어는 벡터 공간상에서 비슷한 위치에 있음

Word2Vec의 결과

유사한 단어 -> 가까운 벡터

이를 통해 의미 관계를 표현 가능

king-man+woman = queen





Embedding

의미를 담을 수 있는 벡터 표현

- 이산적인 데이터를 연속적인 벡터로 변환
- 단어, 문장, 토큰 -> 벡터